

Глубокое обучение в компьютерном зрении

лекции - Иван Загайнов
семинары - Борис Зимка

1. Интро.

Что такое backpropagation и зачем он нужен.

Тренировка нейросетей. Back-propagation

Нейросеть – это дифференцируемая сложная функция, зависящая от параметров:

$$y = f(\vec{x}, W_x)$$

Тренировка нейросетей. Back-propagation

Нейросеть – это дифференцируемая сложная функция, зависящая от параметров:

$$y = f(\vec{x}, W_x) = f(g_x(\vec{v}, W_v), W_x)$$

Тренировка нейросетей. Back-propagation

Нейросеть – это дифференцируемая сложная функция, зависящая от параметров:

$$y = f(\vec{x}, W_x) = f(g_x(\vec{v}, W_v), W_x) = f(g_x(h_v(\vec{z}, W_z), W_v), W_x) = \dots = M(I, \Theta)$$


Тренировка нейросетей. Back-propagation

Нейросеть – это дифференцируемая сложная функция, зависящая от параметров:

$$y = f(\vec{x}, W_x) = f(g_x(\vec{y}, W_y), W_x) = f(g_x(h_y(\vec{z}, W_z), W_y), W_x) = \dots = M(I, \Theta)$$

Ищем такие веса, что на данных будет минимальна ошибка L:

$$\Theta = \operatorname{argmin} E_I[L(y_{true}, M(I, \Theta))]$$



Градиентный спуск по $L(w)$ для разных оптимизаторов ([habr](#))

Тренировка нейросетей. Back-propagation

Нейросеть – это дифференцируемая сложная функция, зависящая от параметров:

$$y = f(\vec{x}, W_x) = f(g_x(\vec{y}, W_y), W_x) = f(g_x(h_y(\vec{z}, W_z), W_y), W_x) = \dots = M(I, \Theta)$$

Ищем такие веса, что на данных будет минимальна ошибка L:

$$\Theta = \operatorname{argmin} E_I[L(y_{true}, M(I, \Theta))]$$

Для этого используем градиентный спуск:

$$\Theta_{i+1} = \Theta_i - \alpha \frac{\partial L}{\partial \Theta}$$

Где взять градиент?

Производная сложной функции

$$L(y_1, y_2) = y_1^2 + y_2$$

$$y_1(x_1, x_2, x_3) = x_2 \cdot x_3$$

$$y_2(x_1, x_2, x_3) = x_1 + x_2 + x_3 + w$$

$$L(y_1, y_2) = L(y_1(\vec{x}), y_2(\vec{x})) = L(\vec{x}) = (x_2 \cdot x_3)^2 + (x_1 + x_2 + x_3 + w)$$

Производная сложной функции

$$\begin{aligned}L(y_1, y_2) &= y_1^2 + y_2 \\ y_1(x_1, x_2, x_3) &= x_2 \cdot x_3 \\ y_2(x_1, x_2, x_3) &= x_1 + x_2 + x_3 + w\end{aligned}$$

$$L(y_1, y_2) = L(y_1(\vec{x}), y_2(\vec{x})) = L(\vec{x}) = (x_2 \cdot x_3)^2 + (x_1 + x_2 + x_3 + w)$$

$$dL = \frac{\partial L}{\partial y_1} dy_1 + \frac{\partial L}{\partial y_2} dy_2 \equiv \frac{\partial L}{\partial x_1} dx_1 + \frac{\partial L}{\partial x_2} dx_2 + \frac{\partial L}{\partial x_3} dx_3 + \frac{\partial L}{\partial w} dw$$

Производная сложной функции

$$\begin{aligned}L(y_1, y_2) &= y_1^2 + y_2 \\ y_1(x_1, x_2, x_3) &= x_2 \cdot x_3 \\ y_2(x_1, x_2, x_3) &= x_1 + x_2 + x_3 + w\end{aligned}$$

$$L(y_1, y_2) = L(y_1(\vec{x}), y_2(\vec{x})) = L(\vec{x}) = (x_2 \cdot x_3)^2 + (x_1 + x_2 + x_3 + w)$$

$$dL = \frac{\partial L}{\partial y_1} dy_1 + \frac{\partial L}{\partial y_2} dy_2 \equiv \frac{\partial L}{\partial x_1} dx_1 + \frac{\partial L}{\partial x_2} dx_2 + \frac{\partial L}{\partial x_3} dx_3 + \frac{\partial L}{\partial w} dw$$

$$dL = \frac{\partial L}{\partial y_1} dy_1 + \frac{\partial L}{\partial y_2} dy_2 = \frac{\partial L}{\partial y_1} (2x_2^2 x_3 \cdot dx_3 + 2x_2 x_3^2 \cdot dx_2) + \frac{\partial L}{\partial y_2} (dx_1 + dx_2 + dx_3 + dw)$$

Производная сложной функции

$$\begin{aligned}L(y_1, y_2) &= y_1^2 + y_2 \\ y_1(x_1, x_2, x_3) &= x_2 \cdot x_3 \\ y_2(x_1, x_2, x_3) &= x_1 + x_2 + x_3 + w\end{aligned}$$

$$L(y_1, y_2) = L(y_1(\vec{x}), y_2(\vec{x})) = L(\vec{x}) = (x_2 \cdot x_3)^2 + (x_1 + x_2 + x_3 + w)$$

$$dL = \frac{\partial L}{\partial y_1} dy_1 + \frac{\partial L}{\partial y_2} dy_2 \equiv \frac{\partial L}{\partial x_1} dx_1 + \frac{\partial L}{\partial x_2} dx_2 + \frac{\partial L}{\partial x_3} dx_3 + \frac{\partial L}{\partial w} dw$$

$$dL = \frac{\partial L}{\partial y_1} dy_1 + \frac{\partial L}{\partial y_2} dy_2 = \frac{\partial L}{\partial y_1} (2x_2^2 x_3 \cdot dx_3 + 2x_2 x_3^2 \cdot dx_2) + \frac{\partial L}{\partial y_2} (dx_1 + dx_2 + dx_3 + dw)$$

$$\begin{aligned}&\frac{\partial L}{\partial x_1} dx_1 + \frac{\partial L}{\partial x_2} dx_2 + \frac{\partial L}{\partial x_3} dx_3 + \frac{\partial L}{\partial w} dw = \\&\frac{\partial L}{\partial y_2} dx_1 + \left(\frac{\partial L}{\partial y_1} 2x_2 \cdot x_3^2 + \frac{\partial L}{\partial y_2} \right) dx_2 + \left(\frac{\partial L}{\partial y_1} 2x_3 \cdot x_2^2 + \frac{\partial L}{\partial y_2} \right) dx_3 + \frac{\partial L}{\partial y_2} dw\end{aligned}$$

Выводы

$$y = f(\vec{x}, W_x)$$

$$L = L(y)$$

1. (Forward) Если знаем x (и w) – можем вычислить $y(x)$
2. (Backward) Если знаем $\frac{\partial L}{\partial y}$ – можем вычислить $\frac{\partial L}{\partial x}, \frac{\partial L}{\partial w}$

Вопросы?

2. Практика.

Github репо. Домашка. NumPy.

Практика


https://github.com/abbyy-edu/course_cvdI

1. ДЗ-1
2. NumPy-туториал

3.Свертка

Вывод backpropagation для свертки.

Визуализация



https://github.com/vdumoulin/conv_arithmetic

«Свертка» (кросс-корреляция)

$I[C, H, W]$, $K[1, C, D, D]$, $O[1, H, W]$ – input, kernel, output

Введём симметричный индекс kernel $d = \frac{D-1}{2}$, размер kernel - всегда нечетный

$$O[h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{C-1 \atop d, d} I[c, h + y, w + x] \cdot K[c, y, x]$$

«Свертка» (кросс-корреляция)

$I[C, H, W], K[1, C, D, D], O[1, H, W]$ – input, kernel, output

$d = \frac{D-1}{2}$, размер kernel всегда нечетный (пусть $D=3, d=1$)

$$O[h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{C-1} \sum_{\substack{d, d}} I[c, h + y, w + x] \cdot K[c, y, x]$$

$$O[h, w] = \sum_{c=0}^{C-1} \\ I[c, h - 1, w - 1] \cdot K[c, -1, -1] + I[c, h, -1, w + 0] \cdot K[c, -1, 0] + I[c, h + 1, w - 1] \cdot K[c, -1, -1] \\ I[c, h - 1, w + 0] \cdot K[c, +0, -1] + I[c, h, -1, w + 0] \cdot K[c, +0, 0] + I[c, h + 1, w - 1] \cdot K[c, +0, -1] \\ I[c, h - 1, w + 1] \cdot K[c, +1, -1] + I[c, h, -1, w + 0] \cdot K[c, +1, 0] + I[c, h + 1, w - 1] \cdot K[c, +1, -1]$$

Q: Между вычислением $O[0, 2]$ и, например, $O[1, 3]$ будет небольшое различие. В чём?

«Свертка» (кросс-корреляция)

$I[C, H, W], K[1, C, D, D], O[1, H, W]$ – input, kernel, output

$d = \frac{D-1}{2}$, размер kernel всегда нечетный

$$O[h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{C-1} \sum_{\substack{d, d}}^{d, d} I[c, h+y, w+x] \cdot K[c, y, x] \quad - \text{ ломается на краях!}$$

У input получаются негативные индексы – добавим zero-padding

$$\hat{I}[c, -d:H-1+d, -d:W-1+d] = \text{Pad}(I, d)$$

$$O[h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{C-1} \sum_{\substack{d, d}}^{d, d} \hat{I}[c, h+y, w+x] \cdot K[c, y, x] = CC(\hat{I}, K)$$

Градиенты «свертки»

$$O[h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{C-1} \hat{I}[c, h+y, w+x] \cdot K[c, y, x] = f_K(I)$$

$$\textcolor{red}{d}O[1, h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{C-1} \textcolor{red}{d}\hat{I}[c, h+y, w+x] \cdot K[c, y, x] + \hat{I}[c, h+y, w+x] \cdot \textcolor{red}{d}K[c, y, x]$$

Нам нужны градиенты:

- $\frac{\partial L}{\partial K[c, y, x]}$ - чтобы «подправить» K
- $\frac{\partial L}{\partial I[c, h, w]}$ - чтобы передать дальше по графу вычислений

Градиенты «свертки»: $\frac{\partial L}{\partial K[c, y, x]}$

$$dL = \sum_{h, w=0}^{H-1, W-1} \frac{\partial L}{\partial O[h, w]} dO[h, w] = \sum_{h, w=0}^{H-1, W-1} \frac{\partial L}{\partial O} [h, w] dO[h, w]$$

$$dO[1, h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{d, d} d\hat{I}[c, h+y, w+x] \cdot K[c, y, x] + \hat{I}[c, h+y, w+x] \cdot dK[c, y, x]$$

$$dO[1, h, w] = \sum_{\substack{c=0 \\ x, y=-d}}^{d, d} \cancel{d\hat{I}[c, h+y, w+x] \cdot K[c, y, x]} + \hat{I}[c, h+y, w+x] \cdot dK[c, y, x]$$

$$dL = \dots + \sum_{h, w=0}^{H-1, W-1} \frac{\partial L}{\partial O[h, w]} \sum_{\substack{c=0 \\ x, y=-d}}^{d, d} \hat{I}[c, h+y, w+x] \cdot dK[c, y, x]$$

Градиенты «свертки»: $\frac{\partial L}{\partial K[c, y, x]}$

$$dL = \dots + \sum_{h,w=0}^{H-1,W-1} \frac{\partial L}{\partial O[h, w]} \sum_{\substack{c=0 \\ x,y=-d}}^{C-1, d, d} \hat{I}[c, h + y, w + x] \cdot dK[c, y, x]$$

$$dL = \dots + \sum_{\substack{c=0 \\ x,y=-d}}^{C-1, d, d} dK[c, y, x] \sum_{h,w=0}^{H-1,W-1} \hat{I}[c, h + y, w + x] \frac{\partial L}{\partial O[h, w]}$$

Q: Через какую операцию можно записать выделенную жирным часть формулы?

Градиенты «свертки»: $\frac{\partial L}{\partial K[c, y, x]}$


$$dL = \dots + \sum_{h, w=0}^{H-1, W-1} \frac{\partial L}{\partial O[h, w]} \sum_{\substack{c=0 \\ x, y=-d}}^{C-1, d} \hat{I}[c, h + y, w + x] \cdot dK[c, y, x]$$

$$dL = \dots + \sum_{\substack{c=0 \\ x, y=-d}}^{C-1, d} dK[c, y, x] \sum_{h, w=0}^{H-1, W-1} \hat{I}[c, h + y, w + x] \frac{\partial L}{\partial O[h, w]}$$

$$dL = \dots + \sum_{\substack{c=0 \\ x, y=-d}}^{C-1, d} dK[c, y, x] \cdot CC\left(\hat{I}[c], \frac{\partial L}{\partial O}\right)$$

$$\frac{\partial L}{\partial K[c]} = CC\left(\hat{I}[c], \frac{\partial L}{\partial O}\right)$$

Градиент K: «свертка» Input и градиента O.



https://github.com/vdumoulin/conv_arithmetic

Градиенты «свертки»: $\frac{\partial L}{\partial I[c, h, w]}$

$$dL = \sum_{h,w=0}^{H-1,W-1} \frac{\partial L}{\partial O[h, w]} dO[h, w]$$

$$dO[h, w] = \sum_{\substack{c=0 \\ x,y=-d}}^{C-1} d\hat{I}[c, h+y, w+x] \cdot K[c, y, x] + \hat{I}[c, h+y, w+x] \cdot dK[c, y, x]$$

$$dL = \sum_{h,w=0}^{H-1,W-1} \frac{\partial L}{\partial O[h, w]} \sum_{\substack{c=0 \\ x,y=-d}}^{C-1} d\hat{I}[c, h+y, w+x] \cdot K[c, y, x] + \dots$$

Градиенты «свертки»: $\frac{\partial L}{\partial I[c, h, w]}$

$$dL = \sum_{h, w=0}^{H-1, W-1} \frac{\partial L}{\partial O[h, w]} \sum_{\substack{c=0 \\ x, y=-d}}^{C-1, d} d\hat{I}[c, h + y, w + x] \cdot K[c, y, x] + \dots$$

Q: Индексы в dI варьируются по x и y . Что делать?

Градиенты «свертки»: $\frac{\partial L}{\partial I[c, h, w]}$

$$dL = \sum_{h, w=0}^{H-1, W-1} \frac{\partial L}{\partial O[h, w]} \sum_{\substack{c=0 \\ x, y=-d}}^{C-1, d, d} d\hat{I}[c, h + y, w + x] \cdot K[c, y, x] + \dots$$

$$\begin{aligned}\hat{h} &= h + y \\ \hat{w} &= w + x\end{aligned}$$

$$dL = \sum_{\substack{\hat{h}, \hat{w}=-d \\ c=0}}^{H-1+d, W-1+d, C-1, d, d} \frac{\partial L}{\partial O[\hat{h} - y, \hat{w} - x]} d\hat{I}[c, \hat{h}, \hat{w}] K[c, y, x] + \dots$$

Градиенты «свертки»: $\frac{\partial L}{\partial I[c, h, w]}$

$$dL = \sum_{\hat{h}, \hat{w} = -d}^{H-1+d, W-1+d} \sum_{\substack{c=0 \\ x, y = -d}}^{C-1, d} \frac{\partial L}{\partial O[\hat{h} - y, \hat{w} - x]} K[c, y, x] d\hat{I}[c, \hat{h}, \hat{w}] + \dots$$

Градиенты «свертки»: $\frac{\partial L}{\partial I[c, h, w]}$

$$dL = \sum_{\hat{h}, \hat{w} = -d}^{H-1+d, W-1+d} \sum_{\substack{c=0 \\ x, y = -d}}^{C-1, d} \frac{\partial L}{\partial O[\hat{h} - y, \hat{w} - x]} K[c, y, x] d\hat{I}[c, \hat{h}, \hat{w}] + \dots$$

$$\hat{x} = -x$$

$$\hat{y} = -y$$

Градиенты «свертки»: $\frac{\partial L}{\partial I[c, h, w]}$

$$dL = \sum_{\hat{h}, \hat{w} = -d}^{H-1+d, W-1+d} \sum_{\substack{d, d \\ c=0 \\ x, y = -d}}^{C-1} \frac{\partial L}{\partial O[\hat{h} - y, \hat{w} - x]} K[c, y, x] d\hat{I}[c, \hat{h}, \hat{w}] + \dots$$

$$\hat{x} = -x$$

$$\hat{y} = -y$$

$$K[c, x, y] = \textcolor{red}{K}[c, -\hat{x}, -\hat{y}] = \hat{K}[c, \hat{x}, \hat{y}]$$

$$dL = \sum_{\hat{h}, \hat{w} = -d}^{H-1+d, W-1+d} \sum_{\substack{d, d \\ c=0 \\ \hat{x}, \hat{y} = -d, -d}}^{C-1} \frac{\partial L}{\partial O[\hat{h} + \hat{y}, \hat{w} + \hat{x}]} \textcolor{red}{\hat{K}}[c, \hat{y}, \hat{x}] \textcolor{green}{d\hat{I}}[c, \hat{h}, \hat{w}] + \dots$$

$$\frac{\partial L}{\partial I[c]} = CC\left(\frac{\partial L}{\partial O}, \textcolor{red}{\hat{K}}[c]\right)$$

Выводы

$$O = CC(\hat{I}, K)$$

$$\frac{\partial L}{\partial \hat{I}[c]} = CC\left(\frac{\partial L}{\partial O}, \hat{K}[c]\right)$$

$$\frac{\partial L}{\partial K[c]} = CC\left(\hat{I}[c], \frac{\partial L}{\partial O}\right)$$

Обозначения:

- CC – это кросс-корреляция
- \hat{I} - это I с паддингами
- \hat{K} - это K с обратной индексацией (повернутое на 180 градусов)

Выводы

$$O = CC(\hat{I}, K)$$

$$\frac{\partial L}{\partial \hat{I}[c]} = CC\left(\frac{\partial L}{\partial O}, \hat{K}[c]\right)$$

$$\frac{\partial L}{\partial K[c]} = CC\left(\hat{I}[c], \frac{\partial L}{\partial O}\right)$$

Заметки:

- Будьте внимательны с индексами и паддингами
- Помните, что в «свертке» также есть добавление bias: $O = CC(I, K) + b$
- Помните, что Kernel имеет размер [G, C, D, D], а Output[G, H, W]
- Используйте для дебага результаты torch

Выводы

$$O = CC(\hat{I}, K)$$

$$\frac{\partial L}{\partial \hat{I}[c]} = CC\left(\frac{\partial L}{\partial O}, \hat{K}[c]\right)$$

$$\frac{\partial L}{\partial K[c]} = CC\left(\hat{I}[c], \frac{\partial L}{\partial O}\right)$$

В домашке нет:

- Dilation («разреженных сверток»)
- Четных размеров Kernel **И** Input
- Stride (шаг) > 1